


Chapitre 13

Apprentissage non supervisé



Dans l'apprentissage non supervisé, on dispose d'un jeu de données non étiquetées et on cherche à dégager les similitudes pouvant exister entre certaines de ces données en les regroupant en différentes catégories : on cherche à les partitionner. On appelle cela le *clustering*, parfois (mal?) traduit en classification (mais à ne pas confondre avec la classification effectuée dans la partie précédente).

L'objectif d'un clustering est de créer des classes d'équivalence où on maximise l'homogénéité au sein d'une classe, et on maximise l'hétérogénéité entre différentes classes. Comme pour la classification du chapitre précédent, on utilisera une fonction de distance qui pourra varier selon les données utilisées.

1 Clustering hiérarchique ascendant

Le clustering hiérarchique ascendant (ou CHA) consiste à regrouper les données petit à petit en fonction de leur proximité avec d'autres données. L'approche est relativement simple et peut se résumer en :

Require: ensemble de données $x_1, \dots, x_N$

Créer N classes $\{x_1\}, \dots, \{x_N\}$

while necessary do

 Fusionner les deux classes les plus proches

Dans l'algorithme précédent, certaines choses sont implicites :

- La condition « necessary » de la boucle **while** peut avoir différentes interprétations, on peut choisir d'arrêter le regroupement lorsque :
 - un nombre de classes déterminé à l'avance a été atteint
 - les deux classes les plus proches sont suffisamment éloignées l'une de l'autre
 - le diamètre d'une des classes devient trop important
- Par ailleurs, la notion de « plus proches » est volontairement vague. On peut obtenir des résultats différents selon la distance $\Delta(A, B)$ choisie pour deux classes A et B :
 - liaison simple : $\min\{\delta(x, y) \mid x \in A, y \in B\}$
 - liaison complète : $\max\{\delta(x, y) \mid x \in A, y \in B\}$
 - liaison moyenne : $\frac{1}{|A||B|} \sum_{x \in A, y \in B} \delta(x, y)$
 - liaison barycentrique : $\delta(b_A, b_B)$ où b_A et b_B sont les barycentres de A et B
 - liaison de Ward : $\sqrt{\frac{|A||B|}{|A| + |B|}} \delta(b_A, b_B)$ correspondant à une liaison barycentrique en donnant moins de poids aux classes composées de données isolées.
 - ...

Remarque 1 Une distance d pourra être utilisée dans cet algorithme si elle est monotone c'est-à-dire si pour trois clusters C_i, C_j et C_k on a :

$$\min(d(C_i, C_j), d(C_i, C_k)) \leq d(C_i, C_j \cup C_k)$$


Ainsi la fusion de deux clusters ne diminue pas la distance à un troisième cluster.

Exemple 1 On considère l'ensemble de points suivant :


$$x_1(10, 6) ; x_2(4, 7) ; x_3(3, 5) ; x_4(5, 1) ; x_5(9, 4) ; x_6(9, 1) ; x_7(4, 2) ; x_8(2, 2) ; x_9(5, 8)$$

On souhaite appliquer l'algorithme CHA par liaison simple, avec une distance maximale avant fusion de deux clusters de 3. On obtient les fusions successives suivantes (les cas d'égalité sont simultanés) et les classes suivantes :

- x_2, x_3 et x_9
- x_1, x_5 et x_6
- x_4, x_7 et x_8




On peut d'ailleurs représenter l'ordre des fusions par un **dendrogramme** (qu'on a continué ici jusqu'à la fusion des classes) :



Remarque 2 Bien que simple à appréhender, le CHA possède deux inconvénients :

1. il n'y a pas de « remise en question » : deux classes fusionnées ne seront jamais séparées
2. la complexité peut être élevée : la recherche des deux classes les plus proches peut prendre un temps $\mathcal{O}(N^2)$, ce qui donne une complexité totale en $\mathcal{O}(N^3)$ (et encore ... seulement si les structures de données sont optimisées).

Exemple 2 Reprendre l'exemple précédent et déterminer le dendrogramme correspondant à un CHA avec liaison complète.



2 k -moyennes

L'algorithme des k -moyennes est un algorithme qui cherche à construire un nombre de clusters défini à l'avance (appelé k dans la littérature, mais qu'on notera m en cohérence avec les parties précédentes).

L'objectif est de résoudre le problème CLUSTERING.

CLUSTERING

- **Instance** : un ensemble de données $E = \{x_1, \dots, x_N\}$ et un entier m
- **Solution** : une partition de E en m classes $C_1, \dots, C_m$
- **Optimisation** : minimiser $\sum_{j=1}^m \sum_{x \in C_j} \delta(x, b_j)^2$ où b_j est le barycentre de la classe C_j

Cependant, ce problème d'optimisation est NP-difficile donc l'algorithme présenté ici est une heuristique considérée comme satisfaisante mais qui peut renvoyer un résultat non-optimal. L'idée de l'algorithme est la suivante :

Algorithme - k -moyennes

Créer m points $b_1, \dots, b_m$ (soit au hasard dans l'espace considéré, soit choisis parmi les x_i)
while les x_i changent **do**
 Affecter à chaque point x_i la classe j correspondant au barycentre b_j qui lui est le plus proche
 Modifier chaque b_j en le barycentre de la nouvelle classe j

Proposition - Complexité de la boucle while

Chaque itération de la boucle while de l'algorithme précédent a une complexité $\mathcal{O}(m \times N)$.

Proposition - Terminaison

L'algorithme des k -moyennes termine.

Remarque 3 L'algorithme des k -moyennes, bien que généralement plus rapide que l'algorithme de clustering hiérarchique ascendant présente certains défauts :

- Le choix initial des b_j est un point critique de l'algorithme. Un mauvais choix peut entraîner un grand déséquilibre par rapport à une solution optimale (si les points choisis sont éloignés des données réelles, ou si deux points sont initialement choisis très proches).
- Il peut converger vers un minimum local qui n'est pas un minimum global.
- En pratique, on fixe un nombre d'itération plutôt que d'attendre la convergence.
- Il n'est valable que pour des classes convexes, ce qui n'est pas le cas de CHA.

3 Exercice

On considère l'ensemble de points :


$$x_1(2, 10) ; x_2(2, 5) ; x_3(8, 4) ; x_4(5, 8) ; x_5(7, 5) ; x_6(6, 4) ; x_7(1, 2) ; x_8(4, 9)$$

1. Faire une figure précise
2. En supposant qu'on souhaite obtenir 3 classes, appliquer l'algorithme des k -moyennes avec des barycentres initialisés à $\{x_1, x_4, x_7\}$.
3. En supposant qu'on arrête les fusions lorsque la distance entre deux clusters dépasse 4, appliquer l'algorithme CHA par liaison simple.


On mesurera une approximation des distances à la règle.

CORRIGÉ

1. On fait face à la situation suivante :



2. On obtient les 3 classes suivantes à la fin du process :



3. On obtient les classes suivantes à la fin du processus :

